

## Mestrado Profissional em Segurança Cibernética

Linha de pesquisa: Segurança e inteligência Cibernética

# BUSCA PROATIVA POR SPYWARES EM AMBIENTES WINDOWS BASEADA EM MULTIPLOS AGENTES DE INTELIGÊNCIA ARTIFICIAL

**Aluno:** Paulo Matheus Nicolau Silva

**Orientador:** Prof. Dr. Daniel Alves da Silva

**Co-Orientador:** Prof. Dr. Robson de Oliveira Albuquerque

Brasília, 11 de julho de 2025

# ✓ AGENDA

1. TEMA
2. PROBLEMA
3. TRABALHOS CORRELATOS
4. OBJETIVO GERAL
5. OBJETIVOS ESPECÍFICOS
6. HIPÓTESE
7. JUSTIFICATIVA
8. METODOLOGIA
9. RESULTADOS ESPERADOS
10. LIMITAÇÕES



# TEMA

**BUSCA PROATIVA POR SPYWARES EM AMBIENTES WINDOWS  
BASEADA EM MULTIPLOS AGENTES DE INTELIGÊNCIA ARTIFICIAL**

## ✓ PROBLEMA

O problema central da cibersegurança contemporânea reside em um duplo desafio: o aumento vertiginoso na frequência de ataques sofisticados e a capacidade desses ataques de permanecerem invisíveis por longos períodos dentro das redes. O relatório "Hello 0-Days, My Old Friend" do Google já estabelece um cenário alarmante, com dezenas de explorações zero-day anualmente e um foco crescente em alvos corporativos por parte de atores avançados, como os *Commercial Surveillance Vendors* (GOOGLE, 2025). Agravando este quadro, o novo relatório M-Trends de 2025 da Mandiant revela que o tempo médio para detectar uma intrusão continua perigosamente alto, permitindo que adversários operem sem serem detectados por semanas ou até meses (MANDIANT, 2025). Essa combinação de alta frequência de ataques e longa permanência do adversário na rede expõe uma lacuna crítica que os sistemas de segurança tradicionais, focados em ameaças conhecidas, não conseguem mais suprir de forma eficaz.

GOOGLE. **Hello 0-Days, My Old Friend: A 2024 Zero-Day Exploitation Analysis**. Google for Cloud Blog, 24 abr. 2025. Disponível em: <https://cloud.google.com/blog/topics/threat-intelligence/2024-zero-day-trends>. Acesso em: 10 jul. 2025.

MANDIANT. **M-Trends 2025: A View From the Front Lines**. Reston, VA: Google Cloud, abr. 2025. Disponível em: <https://cloud.google.com/security/resources/m-trends>. Acesso em: 10 jul. 2025.

## ✓ TRABALHOS CORRELATOS

Este trabalho fundamenta-se na convergência de pesquisas consolidadas no campo da cibersegurança. A literatura demonstra que sistemas multi-agente apresentam eficácia significativa na detecção de ameaças através de agentes especializados (FINISTRELLA; MARIANI; ZAMBONELLI, 2025). Pesquisas recentes evidenciam que agentes equipados com modelos de aprendizado profundo alcançam precisão elevada na identificação de comportamentos maliciosos em malwares (NAZIM et al., 2025). Estudos sobre análise comportamental distribuída revelam sua importância para correlacionar eventos e detectar padrões anômalos através de múltiplos pontos de observação (MOHAMED, 2025). Adicionalmente, técnicas proativas de busca por ameaças têm se mostrado fundamentais para superar as limitações dos métodos reativos tradicionais, especialmente na identificação de spywares evasivos em ambientes complexos (MAHBOUBI et al., 2024). Esta base teórica sustenta a viabilidade de desenvolver uma arquitetura que integre esses avanços para enfrentar os desafios atuais da detecção de spywares avançados.

FINISTRELLA, S.; MARIANI, S.; ZAMBONELLI, F. Multi-agent reinforcement learning for cybersecurity: classification and survey. **Intelligent Systems with Applications**, v. 26, n. 200495, jun. 2025. DOI: 10.1016/j.iswa.2025.200495.

MAHBOUBI, A. et al. Evolving techniques in cyber threat hunting: a systematic review. **Journal of Network and Computer Applications**, v. 232, p. 1-34, ago. 2024. DOI: 10.1016/j.jnca.2024.104004.

MOHAMED, N. Artificial intelligence and machine learning in cybersecurity: a deep dive into state-of-the-art techniques and future paradigms. **Knowledge and Information Systems**, 2025. DOI: 10.1007/s10115-025-02429-y.

NAZIM, S. et al. Multimodal malware classification using proposed ensemble deep neural network framework. **Scientific Reports**, v. 15, n. 18006, 2025. DOI: 10.1038/s41598-025-96203-3.

## ✓ OBJETIVO GERAL

O objetivo geral deste trabalho é desenvolver uma arquitetura de Agentes de Inteligência Artificial para a prática de busca proativa por ameaças (Threat Hunting), resultando em um sistema inteligente e autônomo. Este sistema será projetado para identificar, analisar e responder à ameaças de spyware em sistemas operacionais Windows, fundamentando sua eficácia na colaboração orquestrada entre múltiplos agentes especializados.

## ✓ OBJETIVOS ESPECÍFICOS

- **Formalizar uma arquitetura de referência** para sistemas multiagente de detecção de ameaças, incluindo especificação de interfaces, protocolos de comunicação e modelos de colaboração entre agentes.
- **Desenvolver um framework de análise comportamental distribuída** específico para spywares, estabelecendo taxonomia de comportamentos suspeitos e mecanismos de correlação entre diferentes camadas do sistema operacional.
- **Criar um protocolo de orquestração adaptativa** que permita a coordenação dinâmica entre agentes baseada no contexto da ameaça, incluindo mecanismos de priorização e escalção.
- **Produzir um conjunto de heurísticas de detecção** derivadas empiricamente da colaboração entre agentes, documentando padrões comportamentais de spywares não capturados por assinaturas tradicionais.
- **Estabelecer um modelo de representação de conhecimento** para ameaças cibernéticas que permita o compartilhamento eficiente de informações entre agentes e facilite o aprendizado incremental do sistema.

## ✓ HIPÓTESE

A presente pesquisa parte da seguinte hipótese central: a utilização de mutiplos Agentes de Inteligência Artificial colaborativos pode melhorar significativamente a capacidade de detecção e resposta a spywares. Pressupõe-se que, através da aplicação de análise comportamental distribuída e de mecanismos de aprendizado contínuo, o sistema proposto será capaz de superar as limitações dos métodos tradicionais, que frequentemente falham em identificar ameaças evasivas e coordenadas.

## ✓ JUSTIFICATIVA

A presente hipótese fundamenta-se em avanços científicos consolidados que demonstram o potencial dos sistemas multiagente. Pesquisas recentes comprovam a eficácia de agentes colaborativos na detecção de ameaças cibernéticas (Finistrella; Mariani; Zambonelli, 2025), especialmente quando equipados com modelos de aprendizado profundo que alcançam precisão elevada na identificação de comportamentos maliciosos (Nazim et al., 2025). Destaca-se o papel emergente dos agentes baseados em modelos de linguagem (LLM) na cibersegurança, que demonstram capacidades promissoras quando integrados a ferramentas adequadas para percepção, análise e execução de tarefas, apesar dos desafios inerentes (Deng et al., 2025). A literatura científica evidencia que a análise comportamental distribuída é fundamental para correlacionar eventos e identificar padrões suspeitos (Mohamed, 2025), especialmente quando combinada com técnicas proativas de busca por ameaças que superam as limitações dos métodos reativos convencionais (Mahboubi et al., 2024). Diante do crescimento exponencial de ataques zero-day e do direcionamento sistemático a ambientes corporativos (Google, 2025), a convergência dessas tecnologias - agentes colaborativos, análise comportamental distribuída e aprendizado contínuo - apresenta-se como caminho viável para detectar e responder efetivamente a spywares que evitam consistentemente os sistemas de detecção tradicionais.

DENG, Z. et al. AI agents under threat: a survey of key security challenges and future pathways. **ACM Computing Surveys**, v. 58, n. 7, p. 1-36, 2025. DOI: 10.1145/3716628.

FINISTRELLA, S.; MARIANI, S.; ZAMBONELLI, F. Multi-agent reinforcement learning for cybersecurity: classification and survey. **Intelligent Systems with Applications**, v. 26, n. 200495, jun. 2025. DOI: 10.1016/j.iswa.2025.200495.

GOOGLE. Threat Horizons Report: AI insights from Google's cybersecurity teams, 2025. Disponível em: [https://services.google.com/fh/files/blogs/threat\\_horizons\\_report.pdf](https://services.google.com/fh/files/blogs/threat_horizons_report.pdf). Acesso em: 11 jul. 2025.

MAHBOUBI, A. et al. Evolving techniques in cyber threat hunting: a systematic review. **Journal of Network and Computer Applications**, v. 232, p. 1-34, ago. 2024. DOI: 10.1016/j.jnca.2024.104004.

MOHAMED, N. Artificial intelligence and machine learning in cybersecurity: a deep dive into state-of-the-art techniques and future paradigms. **Knowledge and Information Systems**, 2025. DOI: 10.1007/s10115-025-02429-y.

NAZIM, S. et al. Multimodal malware classification using proposed ensemble deep neural network framework. **Scientific Reports**, v. 15, n. 18006, 2025. DOI: 10.1038/s41598-025-96203-3.

# ✓ METODOLOGIA

- 1. Definição do Ambiente de Testes:** Desenvolvimento e configuração de máquina virtual (VM) que servirá como base replicável e controlada para os experimentos, simulando um ambiente corporativo padrão.
- 2. Design da Arquitetura:** Modelagem do sistema multi-agente, definindo as especializações, os protocolos de comunicação e a hierarquia de colaboração entre os diferentes agentes de IA.
- 3. Implementação dos Agentes:** Desenvolvimento do código-fonte de cada agente, implementando suas funcionalidades específicas de coleta de dados, análise de comportamento e execução de respostas.
- 4. Treinamento dos Modelos:** Preparação e treinamento dos modelos de aprendizado de máquina de cada agente, utilizando datasets públicos.
- 5. Validação Experimental:** Execução de cenários de ataque simulados no ambiente controlado para testar a capacidade de detecção, a precisão e o tempo de resposta do sistema integrado.
- 6. Análise de Resultados:** Coleta e avaliação das métricas de desempenho (ex: taxa de detecção, falsos positivos) e identificação de pontos para otimização e melhorias futuras no sistema.

## ✓ RESULTADOS ESPERADOS

- **Desenvolvimento de um protótipo funcional** de arquitetura, baseada em agentes de IA especializados e colaborativos para a detecção de spywares.
- **Obtenção de uma taxa de detecção** de spywares superior à de métodos convencionais, acompanhada de uma redução significativa na incidência de falsos positivos.
- **Aprimoramento da segurança** em ambientes operacionais Windows, oferecendo um modelo de defesa mais robusto e proativo contra ameaças.
- **Estímulo a novas pesquisas** na área de sistemas multiagente aplicados à cibersegurança, criando uma base sólida para avanços futuros em detecção adaptativa de ameaças.

## ✓ LIMITAÇÕES

- **Custo Computacional:** A natureza distribuída do sistema impõe um elevado custo computacional, tornando a otimização de recursos uma prioridade e justificando a adoção de modelos de IA mais leves e eficientes sempre que a especialização de um agente permitir.
- **Dependência de Dados:** A eficácia e a precisão dos modelos de IA são diretamente dependentes da qualidade e da atualidade dos datasets de spyware utilizados para o treinamento, o que representa um desafio de manutenção contínua.
- **Evolução das Ameaças:** Novas famílias de spyware com comportamentos radicalmente diferentes podem, inicialmente, evadir a detecção, exigindo atualizações e re-treinamento frequente dos agentes.